

DATA QUALITY

Качество данных в контуре приёмки ЕГАИС

Аудит витрины · расследование дефекта · прототип мониторинга · стратегия

Проектная работа · Data Quality

Почему это важно для нас как оператора системы

- 5 000 организаций передают в ЕГАИС складские операции; на нашей витрине строятся сверка деклараций, отраслевая статистика и основания для контрольных мероприятий.
- Принятый от организаций поток проверен и целостен — значит дефекты витрины возникли внутри нашего контура.
- Искажённый код организации → операцию нельзя сопоставить с реестром лицензиатов; для ИП это ещё и неточные персональные данные (152-ФЗ).
- Выделенной DQ-функции нет, мониторинга не было — дефект жил в витрине месяцами и не был замечен.

ДОМЕН

Государственный учёт оборота алкоголя

ПРИЁМКА / ВИТРИНА

list_doc (приёмка)
→ doc_oper (витрина)

Что показал аудит витрины

ПОЛНОТА ЗАГРУЗКИ

90.0%

100 000 операций не
доехало

ТОЧНОСТЬ КОДА ОРГ.

90.0%

90 000 кодов повреждены

БАЛАНС ПЕРЕМЕЩЕНИЙ

65.0%

не сходится у 96 309 пар

ПАРТИИ (СПРАВКА А)

10 000

задеты потерями все до
одной

- Принятый поток целостен: ключ уникален, обязательные поля заполнены, код организации на 100% валиден
- данные испортились у нас.
- Дефектов два, и они связаны: загрузка потеряла операции, их довосстановили вручную — и при этой правке испортился код организации.
- Справка А сопровождает партию, справка Б — перемещение: номера повторяются по природе документа, поэтому проверяется иерархия, а не уникальность.
- Приёмка (12 колонок) шире витрины (9) — при загрузке 3 атрибута теряются молча, плюс сужается точность количества.

Что нашли и как это классифицировали

#	Проблема	Класс DQ	Затронуто	Критичность
1	100 000 принятых операций не дошли до витрины	Полнота (загрузка)	10% потока	Высокая
2	Код организации теряет ведущий 0 при ручной доводке	Точность / формат	10% витрины	Высокая
3	Баланс перемещений не сходится	Согласованность	35% пар	Высокая
4	Ни одна партия не дошла до витрины целиком	Полнота (следствие 1)	10 000 партий	Высокая
5	Журнал изменений витрины не ведётся	Прослеживаемость	—	Высокая

— Проблема 2 — следствие попытки починить проблему 1: данные доставили вручную и не заметили побочного эффекта (Шаг 6).

14 правил → SQL и Soda Core → ежедневный DAG

- Реестр из 14 бизнес-правил (полнота, точность, валидность, уникальность, согласованность, своевременность, целостность) с владельцами и порогами.
- DQ-14 — баланс перемещения: списать по справке Б больше, чем получено, нельзя. Именно он ловит последствия ручных правок и служит инструментом разбора заявок.
- Каждое правило — исполняемый SQL (02_dq_rules.sql) и конфиг Soda Core (checks.yml); обе реализации прогнаны на реальной БД и дали одинаковый вердикт.
- Airflow DAG развёрнут и работает по расписанию с 23.08: креды из Connection, гейт блокирует публикацию витрины в контур контроля.

ПОСЛЕДНИЙ ПРОГОН

DQ-01	Заполненность		100%
DQ-02	Полнота загрузки		90%
DQ-03	Формат кода		90%
DQ-04	Точность кода		90%
DQ-05	Уникальность		100%
DQ-06	Тип документа		100%
DQ-07	Знак количества		100%
DQ-08	Свежесть дат		100%
DQ-09	Код продукции		100%
DQ-10	Формат справок		100%
DQ-11	Происхождение		100%
DQ-12	Иерархия справок		100%
DQ-13	Однородность		100%
DQ-14	Баланс		65%

Два дашборда: инженерам и контролю рынка

ТЕХНИЧЕСКИЙ (DQ / IT)

- 14 правил, pass rate по каждому
- Тренд critical-правил по дням
- Полная история запусков пайплайна
- Собирается скриптом из БД: ноль ручных цифр
- Прод-вариант — Grafana

БИЗНЕС (КОНТРОЛЬ РЫНКА)

- Один вопрос: «можно ли доверять сегодняшним данным?»
- Явно сказано: организации отчитались корректно
- Обновляется тем же скриптом после каждого прогона

Data Contract + риски по 152-ФЗ и 171-ФЗ

- Data Contract — обязательства команды загрузки перед контуром контроля: схема, SLA свежести, quality-пороги, строковый тип кода организации.
- Искажённый код организации-ИП — это неточные персональные данные: ч. 6 ст. 5 152-ФЗ требует точности, ст. 21 — уточнить с момента выявления.
- Потерянные операции → ошибочные основания для контрольных мероприятий (КоАП ст. 14.19) и искажение отраслевой статистики.

СНИЖАЮТ РИСК

- DQ-02 — ни одна принятая операция не теряется
- DQ-03/DQ-04 — код организации совпадает с принятым
- DQ-11 — в витрину не попадают записи мимо приёмки
- DQ-14 — баланс товародвижения сходится по каждой поставке
- Журнал изменений витрины: кто и когда правил данные — сейчас не ведётся

Расследование: чинили одно — сломали другое

МТТД БЕЗ МОНИТОРИНГА

≈2 734 ч

с мониторингом — ≤ 24 ч

ОБЪЁМ ИСПРАВЛЕНИЯ

5 000 заявок

≈4 190 чел.-ч, очередь ≈16 мес

РАЗБОР ПО БАЛАНСУ

34 195

пар — след вставки; ещё 25 027 — потери загрузки

- Решающая улика: испорчено ровно 10% кодов, а не 100%. Баг внутри ETL задел бы весь поток — значит правили подмножество строк отдельной операцией.
- Реконструкция: загрузка потеряла ≈190 000 операций → 90 000 довосстановили вручную → в этом цикле код организации потерял ведущий ноль → остальные 100 000 не вернули.
- Правило DQ-11 такую вставку не ловит: вставляли реальные операции из приёмки. Ловит DQ-14 — баланс перемещения.
- Чего данные не доказывают: кто и когда выполнил вставку — журнала изменений витрины нет.

Цена инцидента — 5 000 заявок и 4 190 часов

Сценарий	Заявок	Объём работ
Без мониторинга (как есть)	5 000	≈4 190 чел.-ч
Мониторинг + гейт публикации	0	17 чел.-ч
Гейт обошли, данные ушли	810	≈690 чел.-ч

— Заявка = обращение одной организации на исправление её данных; число заявок считается запросом, а не оценивается экспертно.

— Норматив 50 мин на заявку разложен по этапам: приём, сверка с приёмкой, корректировка, ответ.

ОКУПАЕМОСТЬ

142 заявки

столько нужно предотвратить, чтобы окупить 118 часов первого года — это 2.8% одного инцидента

— Вложения: 70 ч разработки + 48 ч/год поддержки

— Даже при окупаемости 10% возврат 3.5×

Что нужно от руководства

- Утвердить владельца DQ-инициативы (совмещение роли на первой итерации, не новый штат).
- 70 часов на разработку (Фазы 0-2) и 4 часа в месяц на поддержку правил.
- Решение по журналу изменений витрины — без него расследования упрутся в догадки.
- 30 минут юриста — классификация организаций юрлицо/ИП для применимости 152-ФЗ.

ДОРОЖНАЯ КАРТА

- Нед. 1-2 — профилирование приёмки и витрины
- Нед. 3-4 — глоссарий и 8-12 правил
- Нед. 5-8 — пайплайн, Soda Core, Airflow
- Нед. 9-10 — Data Contract, журнал изменений
- С нед. 10 — инциденты и учёт заявок