

DATA QUALITY

Качество данных в контуре приёмки ЕГАИС

Аудит витрины · расследование дефекта · прототип мониторинга · стратегия

Проектная работа · Data Quality

Почему это важно для нас как оператора системы

- 5 000 организаций передают в ЕГАИС складские операции; на нашей витрине строятся сверка деклараций, отраслевая статистика и основания для контрольных мероприятий.
- Принятый от организаций поток проверен и целостен — значит дефекты витрины возникли внутри нашего контура.
- Искажённый код организации → операцию нельзя сопоставить с реестром лицензиатов; для ИП это ещё и неточные персональные данные (152-ФЗ).
- Выделенной DQ-функции нет, мониторинга не было — дефект жил в витрине месяцами и не был замечен.

ДОМЕН

Государственный учёт оборота алкоголя

ПРИЁМКА / ВИТРИНА

list_doc (приёмка)
→ doc_oper (витрина)

Что показал аудит: шесть проблем и их масштаб


#	Проблема	Класс DQ	Масштаб	Критичность
1	Принятые операции не дошли до витрины при загрузке	Полнота (загрузка)	100 000 операций · 10% потока	Критичная
2	Код организации теряет ведущий 0 при ручной доводке	Точность / формат	90 000 операций · 10% витрины	Критичная
3	Баланс перемещений не сходится: списано больше, чем получено	Бизнес-логика	96 309 пар · 35%	Критичная
4	Ни одна партия не дошла до витрины целиком	Полнота (следствие 1)	10 000 партий · 100%	Высокая
5	bottling_date и wbpid не заполнены ни разу	Полнота (схема)	1 000 000 строк · 100%	Средняя
6	Журнал изменений витрины не ведётся	Прослеживаемость	вся витрина	Высокая

— Принятый поток целостен: ключ уникален, поля заполнены, код организации валиден на 100% — все дефекты возникли внутри контура.

— Проблема 2 — следствие попытки починить проблему 1. Проблема 3 — их общее последствие и одновременно инструмент разбора.

Как устроен поток данных и контур контроля


ПОТОК ДАННЫХ



сверка витрины с эталоном

PASS / FAIL → гейт

КОНТУР КОНТРОЛЯ КАЧЕСТВА



Гейт и алерт — разные вещи: алерт сообщает людям, гейт не выпускает данные. Провал критичного правила (DQ-02/03/04/11/14) → DAG красный → таск публикации не запускается.

14 правил в трёх категориях — SQL и Soda Core

ПОЛНОТА И ЦЕЛОСТНОСТЬ

DQ-01 Заполненность **PASS 100%**

Все 8 обязательных полей операции не пусты

DQ-02 Полнота загрузки **FAIL 90%**

Сколько принято — столько и доехало до витрины

DQ-05 Уникальность **PASS 100%**

Операция не задвоена повторной загрузкой

DQ-11 Происхождение **PASS 100%**

В витрине нет записей, которых не было в приёмке

ТОЧНОСТЬ И ФОРМАТ

DQ-03 Формат кода **FAIL 90%**

8 цифр с ведущим нулём — иначе не найти в реестре

DQ-04 Точность vs приёмка **FAIL 90%**

Код в витрине совпадает с тем, что прислала организация

DQ-09 Код продукции **PASS 100%**

Положительный, правдоподобной длины

DQ-10 Формат справок **PASS 100%**

Номера деклараций соответствуют шаблону

БИЗНЕС-ЛОГИКА

DQ-07 Знак количества **PASS 100%**

Приход > 0, списание < 0

DQ-12 Иерархия справок **PASS 100%**

Перемещение принадлежит ровно одной партии

DQ-13 Однородность **PASS 100%**

Внутри справки А один код продукции

DQ-14 Баланс поставки **FAIL 65%**

Списать по справке Б больше, чем получено, нельзя

— Ещё два технических правила — DQ-06 тип документа и DQ-08 свежесть — зелёные. Пять критичных (DQ-02/03/04/11/14) блокируют публикацию. Каждое правило — SQL (02_dq_rules.sql) и SodaCL (checks.yml); оба движка на реальной БД дали одинаковый вердикт.

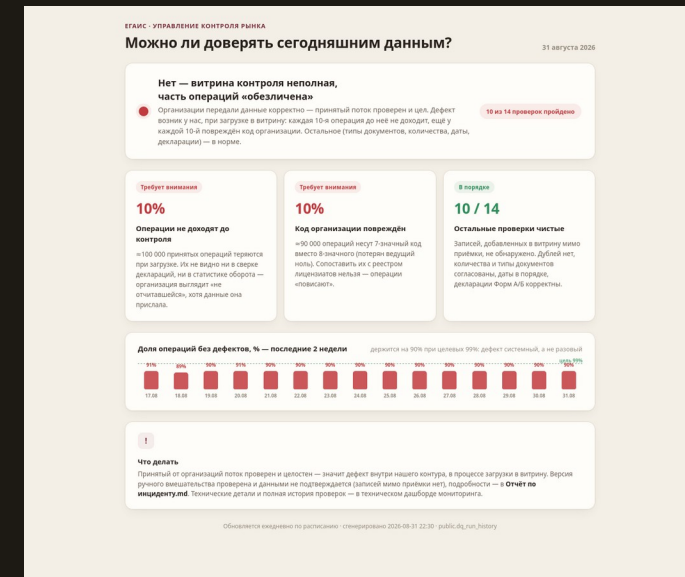
Два дашборда: инженерам и бизнесу

ТЕХНИЧЕСКИЙ · GRAFANA, РАЗВЁРНУТ



- Pass rate по каждому из 14 правил, тренд критичных по дням
- Полная история запусков пайплайна — 40+ прогонов из `dq_run_history`
- Детали последнего FAIL-прогона: какие пары, сколько строк, порог

БИЗНЕС · МОДЕЛЬ ДЛЯ GRAFANA



- Один вопрос: «можно ли доверять сегодняшним данным?»
- Три числа: не доехало, искажён код, не сходится баланс
- Явно сказано: организации отчитались корректно, проблема у нас

Data Contract + риски по 152-ФЗ и 171-ФЗ

- Data Contract — обязательства команды загрузки перед контуром контроля: схема, SLA свежести, quality-пороги, строковый тип кода организации.
- Искажённый код организации-ИП — это неточные персональные данные: ч. 6 ст. 5 152-ФЗ требует точности, ст. 21 — уточнить с момента выявления.
- Потерянные операции → ошибочные основания для контрольных мероприятий (КоАП ст. 14.19) и искажение отраслевой статистики.

СНИЖАЮТ РИСК

- DQ-02 — ни одна принятая операция не теряется
- DQ-03/DQ-04 — код организации совпадает с принятым
- DQ-11 — в витрину не попадают записи мимо приёмки
- DQ-14 — баланс товародвижения сходится по каждой поставке
- Журнал изменений витрины: кто и когда правил данные — сейчас не ведётся

Расследование: чинили одно — сломали другое

МТТД БЕЗ МОНИТОРИНГА

≈2 734 ч

с мониторингом — ≤ 24 ч

ОБЪЁМ ИСПРАВЛЕНИЯ

5 000 заявок

≈4 190 чел.-ч, очередь ≈16 мес

РАЗБОР ПО БАЛАНСУ

34 195

пар — след вставки; ещё 25 027 — потери загрузки

- Решающая улика: испорчено ровно 10% кодов, а не 100%. Баг внутри ETL задел бы весь поток — значит правили подмножество строк отдельной операцией.
- Реконструкция: загрузка потеряла ≈190 000 операций → 90 000 довосстановили вручную → в этом цикле код организации потерял ведущий ноль → остальные 100 000 не вернули.
- Правило DQ-11 такую вставку не ловит: вставляли реальные операции из приёмки. Ловит DQ-14 — баланс перемещения.
- Чего данные не доказывают: кто и когда выполнил вставку — журнала изменений витрины нет.

Цена инцидента — 5 000 заявок и 4 190 часов

Сценарий	Заявок	Объём работ
Без мониторинга (как есть)	5 000	≈4 190 чел.-ч
Мониторинг + гейт публикации	0	17 чел.-ч
Гейт обошли, данные ушли	810	≈690 чел.-ч

— Заявка = обращение одной организации на исправление её данных; число заявок считается запросом, а не оценивается экспертно.

— Норматив 50 мин на заявку разложен по этапам: приём, сверка с приёмкой, корректировка, ответ.

ОКУПАЕМОСТЬ

142 заявки

столько нужно предотвратить, чтобы окупить 118 часов первого года — это 2.8% одного инцидента

— Вложения: 70 ч разработки + 48 ч/год поддержки

— Даже при окупаемости 10% возврат 3.5×

План внедрения в три фазы

ПИЛОТ · 1–2 МЕС

сделано в проекте

- Одна витрина: doc_oper против приёмки list_doc
- 14 правил в SQL и Soda, DAG в Airflow с гейтом
- Технический дашборд в Grafana, история прогонов
- Хотфикс кода организации, дозагрузка потерянных операций

Критерий: MTBD ≤ 24 ч; критичные правила зелёные после бэкфилла

РАСШИРЕНИЕ · 3–6 МЕС

закрываем пробелы инцидента

- Журнал изменений витрины; запись — только учётной записью ETL
- Data Contract согласован с потребителями и подписан
- Бизнес-дашборд в ежедневном обиходе управления контроля
- Алерты в дежурный канал, учёт заявок по инцидентам

Критерий: 0 ручных правок витрины; 0 заявок по DQ-дефектам

МАСШТАБИРОВАНИЕ · 6–12 МЕС

весь контур приёмки

- Остальные витрины — по одной в месяц, те же шаблоны правил
- Проверки на входе приёмки, до попадания в витрину
- Классификация ИП / юрлицо (152-ФЗ), каталог данных с владельцами
- Квартальный пересчёт эффекта, ревизия порогов

Критерий: $\geq 80\%$ витрин под контрактом; дефекты ловятся до витрины

ЧТО НУЖНО ОТ РУКОВОДСТВА

владелец инициативы (совмещение, не новый штат) · 70 ч разработки + 4 ч/мес поддержки · решение по журналу изменений витрины · 30 мин юриста на классификацию ИП / юрлицо